k-Nearest Neighbours

Ali Akbar Septiandri

October 23, 2018

Universitas Al Azhar Indonesia

Daftar isi

Instance-based Learning

Deskripsi Dataset

- Iris dataset
- Pembuat: R.A. Fisher (1936)
- `http://archive.ics.uci.edu/ml/`
- 4 atribut: sepal length, sepal width, petal length, petal width
- 3 label: Iris Setosa, Iris Versicolour, Iris Virginica

Figure 1: Tanaman Iris

Iris Dataset

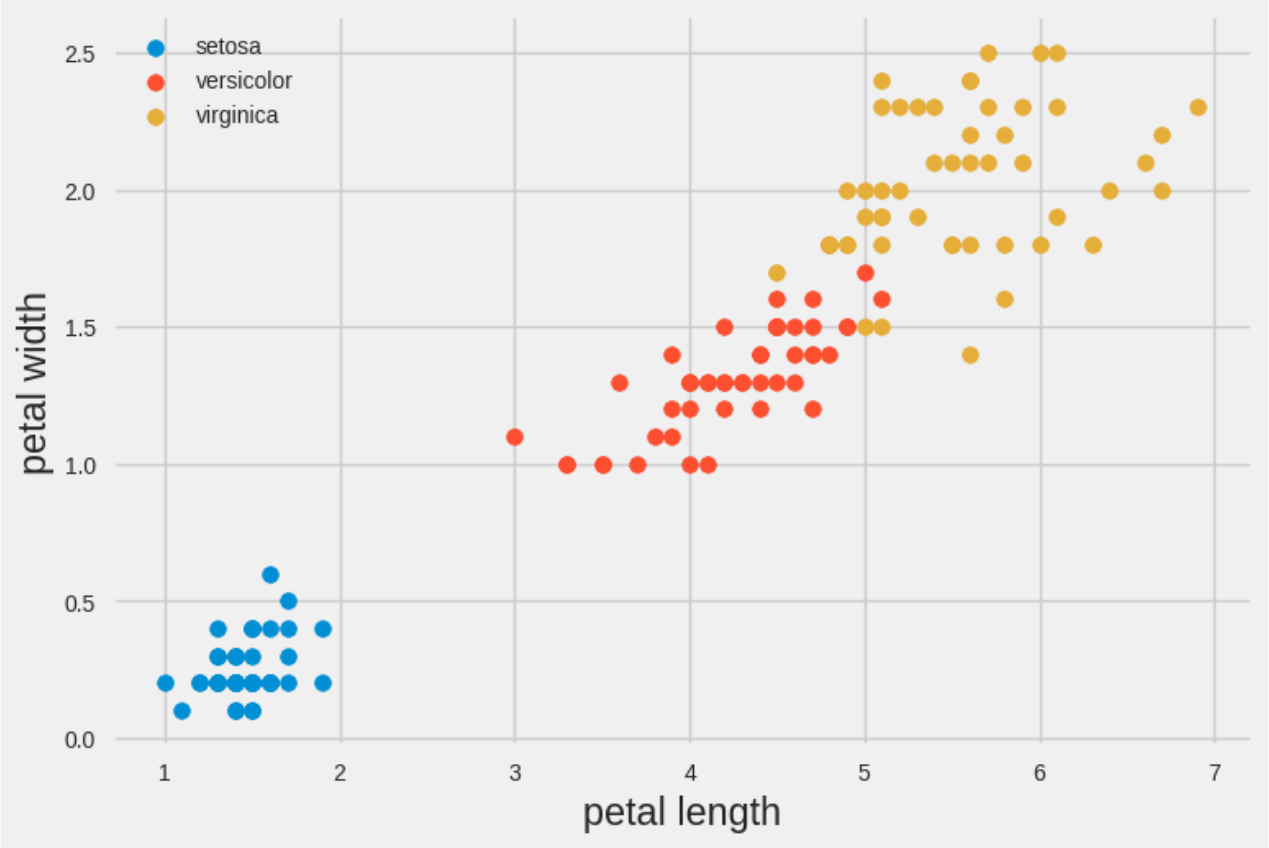

Data Baru

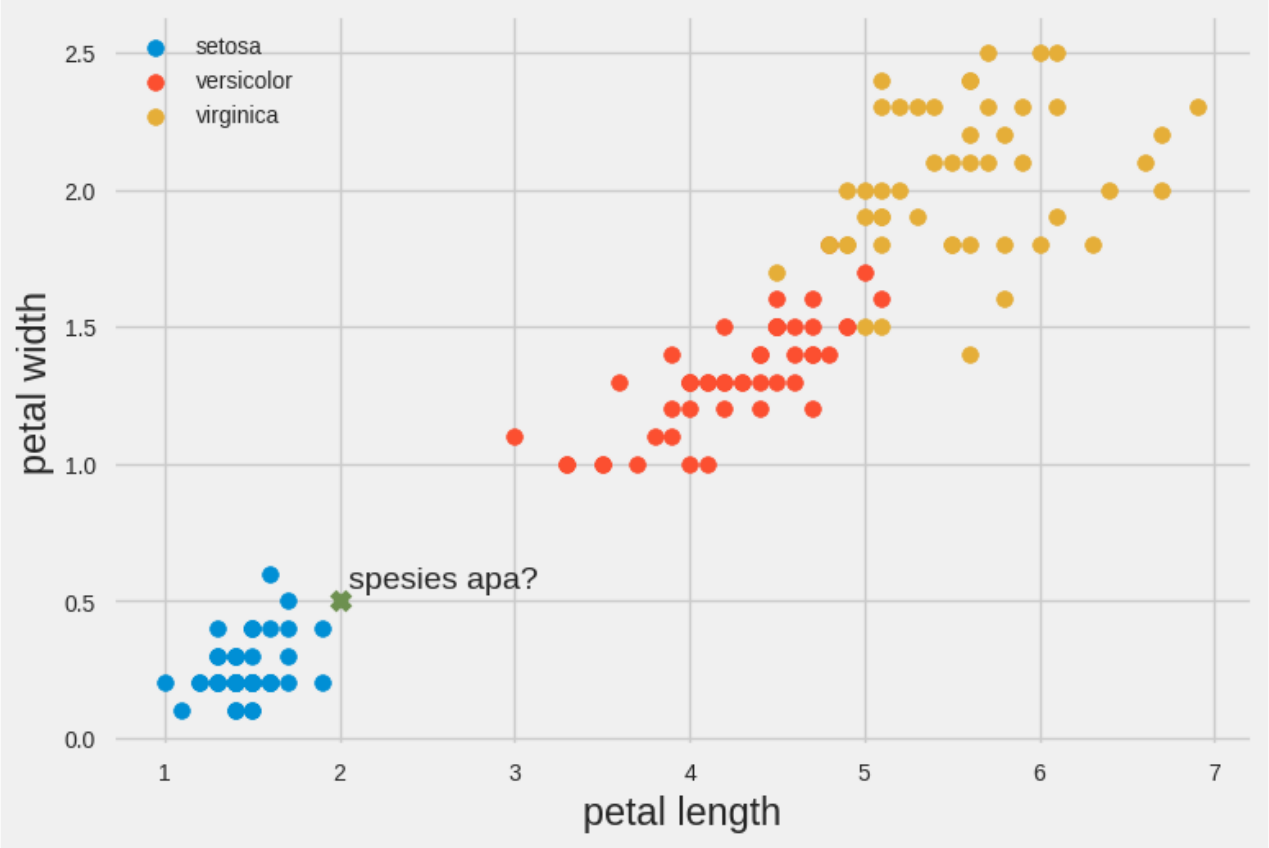
setosa
versicolor
virginica
spesies apa?
petal width
petal length
0.0
0.5
1.0
1.5
2.0
2.5
1
2
3
4
5
6
7

Data Baru

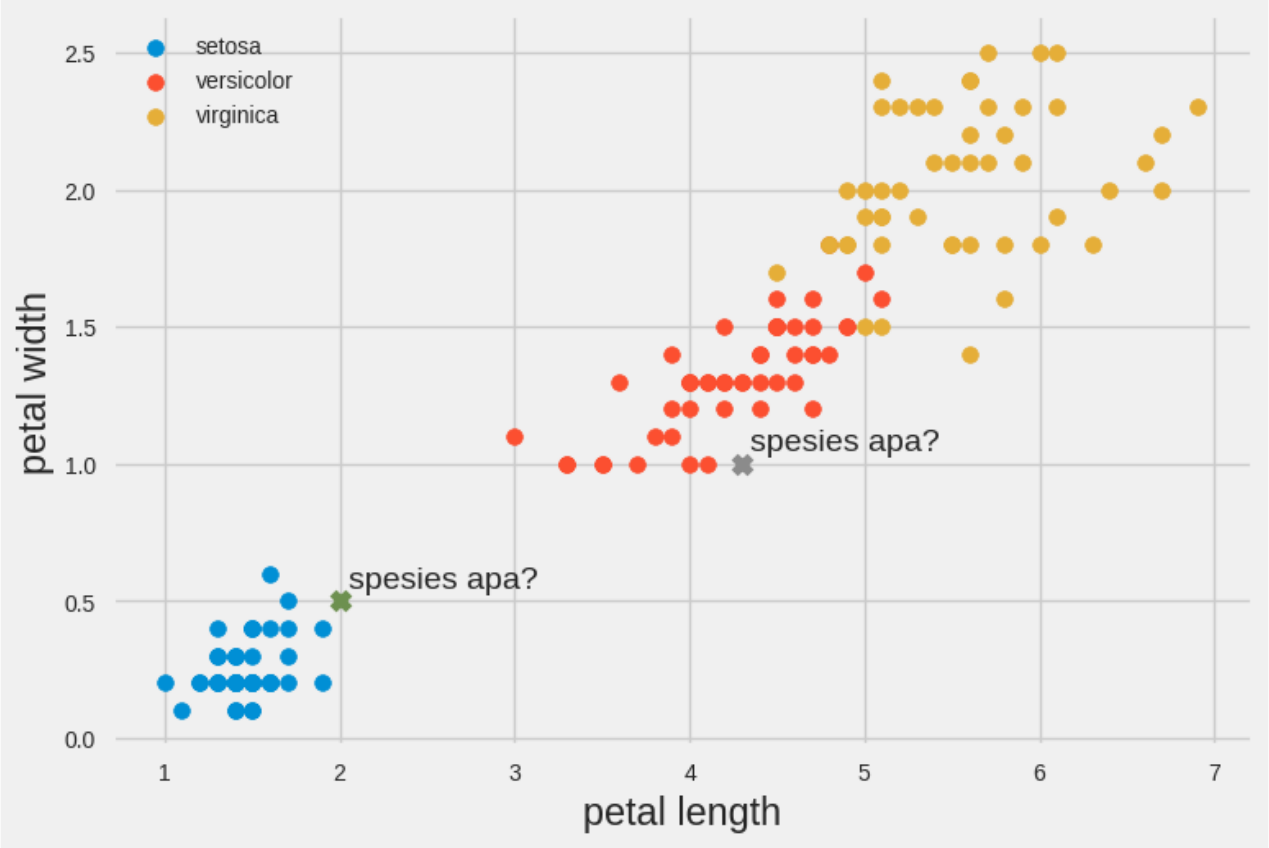
setosa
versicolor
virginica
2.5
2.0
1.5
1.0
0.5
0.0
petal width
1
2
3
4
5
6
7
petal length
spesies apa?
spesies apa?

Nearest Neighbour

- Mencari referensi dari tetangga terdekat

Nearest Neighbour

- Mencari referensi dari tetangga terdekat
- Apa definisi “terdekat”?

Nearest Neighbour

- Mencari referensi dari tetangga terdekat
- Apa definisi “terdekat”?
- Metode umum: **Euclidean distance**

Euclidean Distance

$$d([x_1, x_2, ..., x_d], [y_1, y_2, ..., y_d]) = \sqrt{\sum_{i=1}^{d} (x_i - y_i)^2}$$

Pengukuran Jarak

Figure 2: Manhattan vs Euclidean distance

Masalah

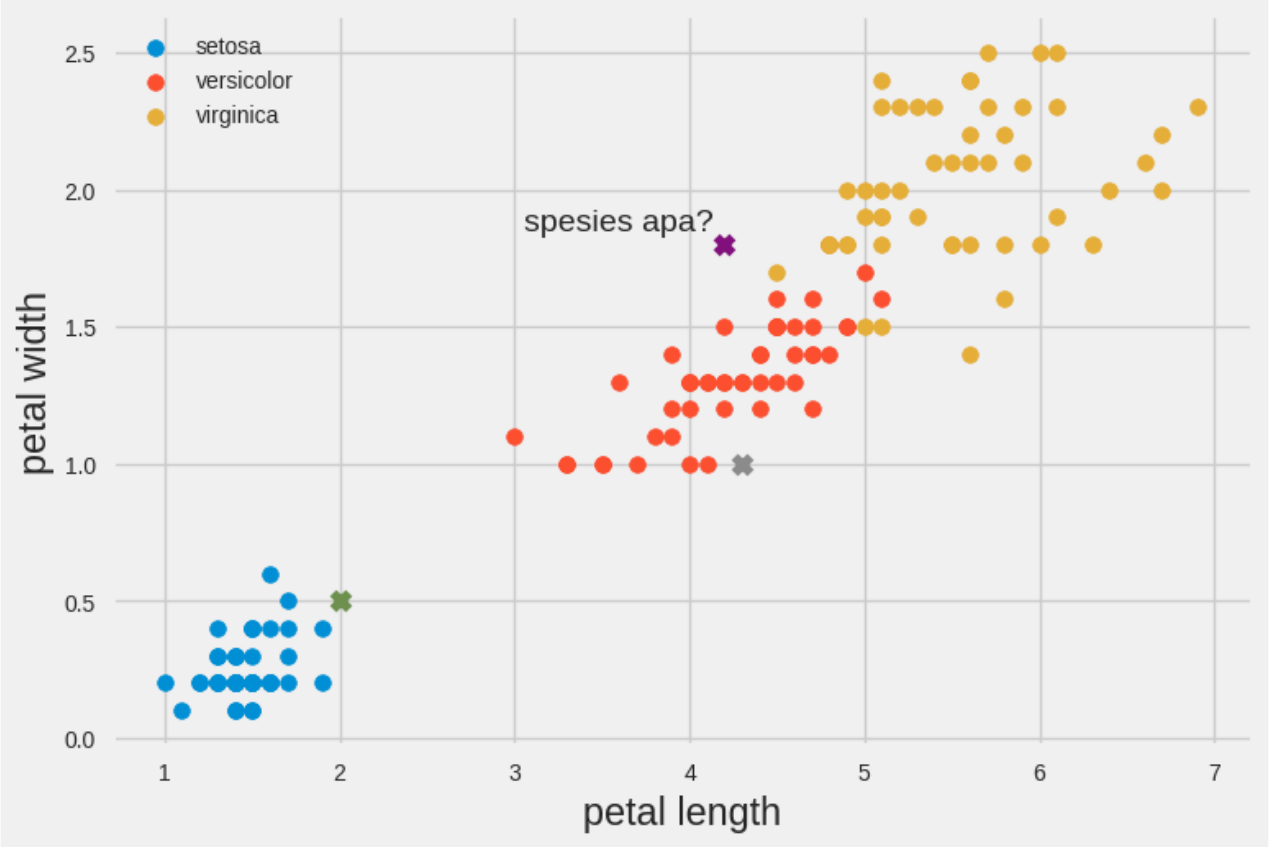

Figure 3: Seberapa yakin kita dengan referensi terdekat?

k-Nearest Neighbours

- Mencari referensi dari beberapa (k) tetangga terdekat

k-Nearest Neighbours

- Mencari referensi dari beberapa (k) tetangga terdekat
- Melihat label mayoritas dari tetangga terdekat

k-Nearest Neighbours

- Mencari referensi dari beberapa (k) tetangga terdekat
- Melihat label mayoritas dari tetangga terdekat
- Perhatikan bahwa harus dihitung jaraknya dengan semua data yang ada

k-Nearest Neighbours

- Mencari referensi dari beberapa (k) tetangga terdekat
- Melihat label mayoritas dari tetangga terdekat
- Perhatikan bahwa harus dihitung jaraknya dengan semua data yang ada
- Kompleksitas: $O(nd)$

k-Nearest Neighbours

- Mencari referensi dari beberapa (k) tetangga terdekat
- Melihat label mayoritas dari tetangga terdekat
- Perhatikan bahwa harus dihitung jaraknya dengan semua data yang ada
- Kompleksitas: $O(nd)$
- *Tidak mungkin kita hitung sendiri!*

Algoritma Klasifikasi

- Diketahui
  - data latih $\{x_i, y_i\}$
    - x_i: nilai atribut
    - y_i: label kelas
  - *instance* uji x
- Algoritma:
  1. Hitung jarak $D(x, x_i)$ untuk semua x_i
  2. Pilih k tetangga terdekat dengan labelnya
  3. $\hat{y} =$ mayoritas dari label tetangga terdekat

Prediksi

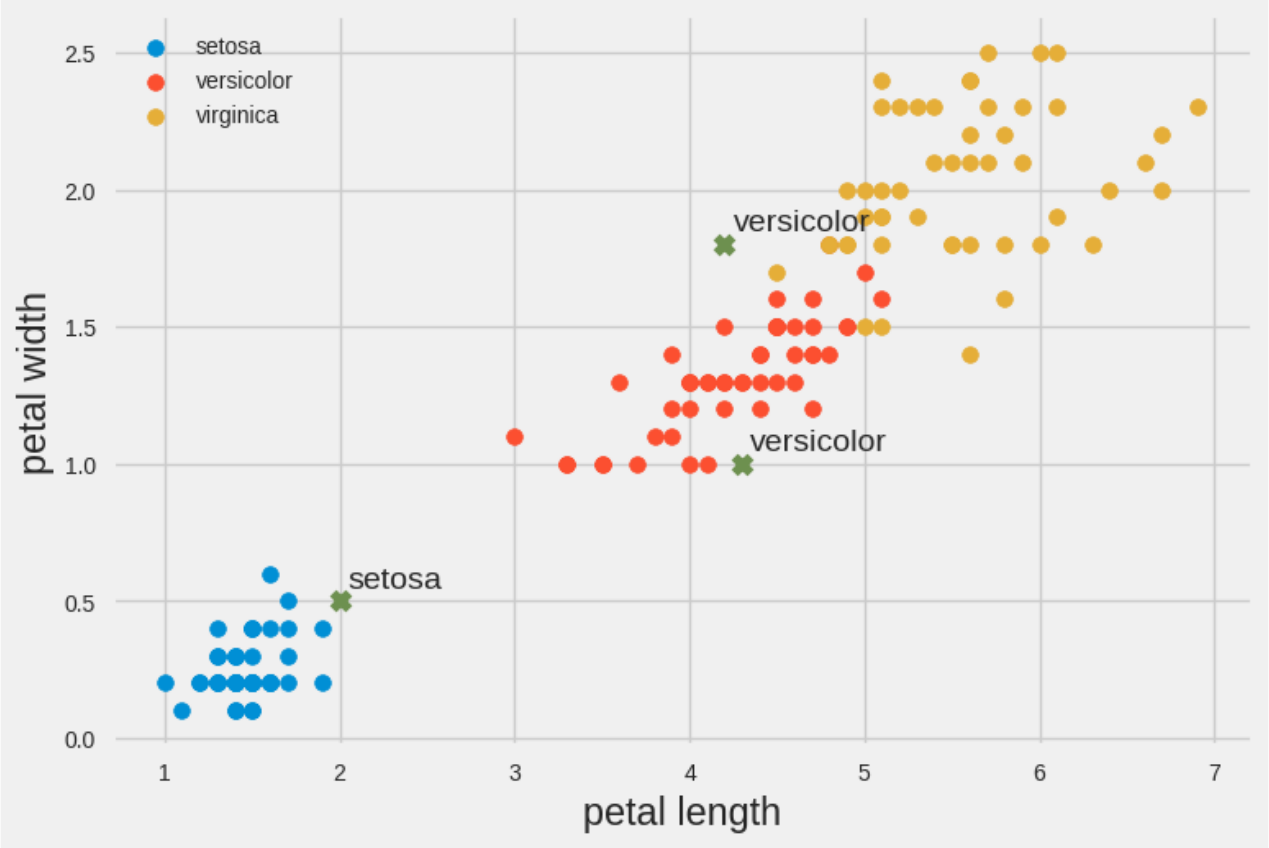
setosa
versicolor
virginica
versicolor
versicolor
setosa
petal width
petal length
0.0
0.5
1.0
1.5
2.0
2.5
1
2
3
4
5
6
7

Klasifikasi k-NN

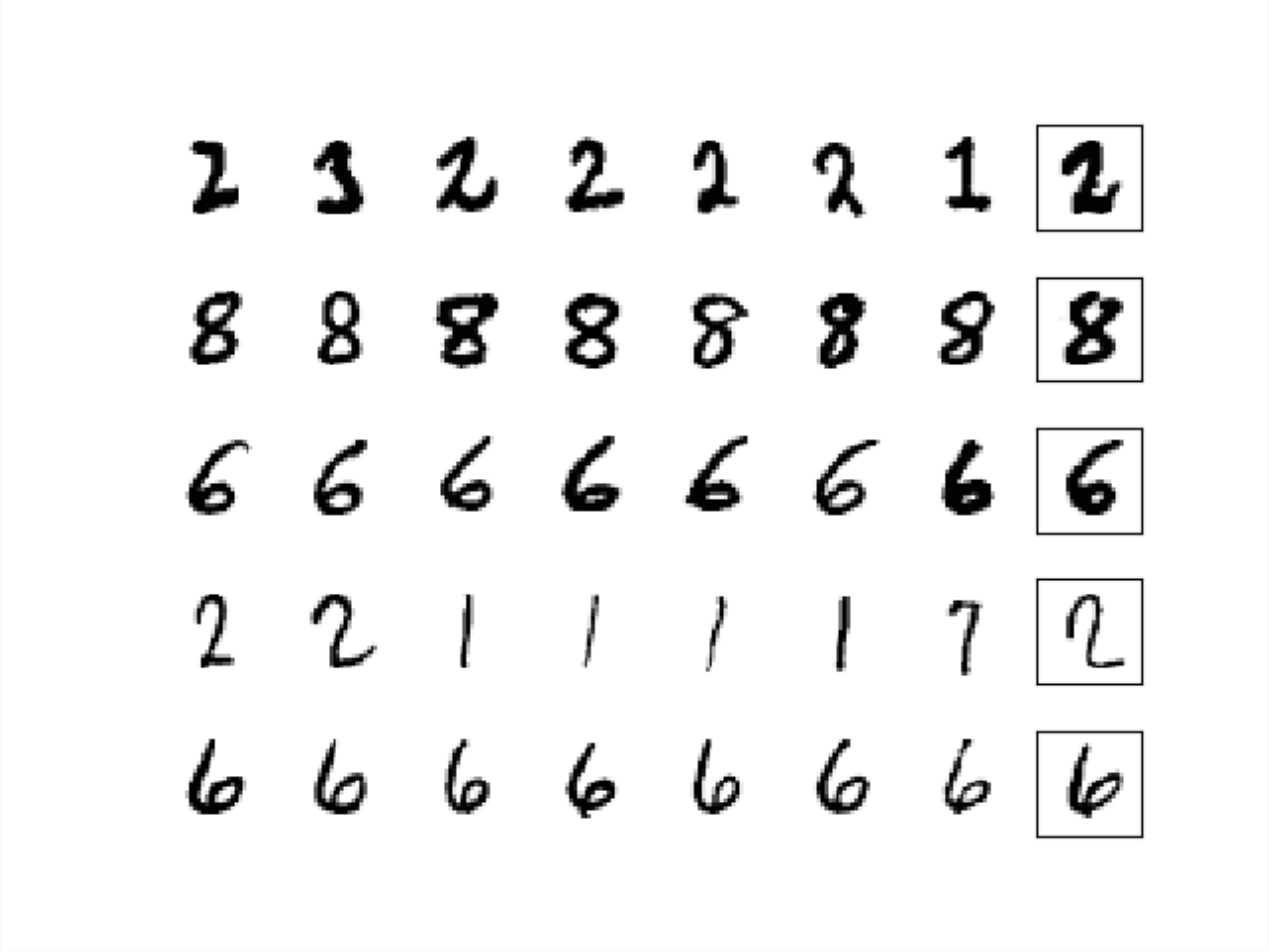

Figure 4: 7-NN pada data MNIST dengan data uji di paling kanan

Regresi

Algoritma Regresi

- Diketahui
  - data latih $\{x_i, y_i\}$
    - x_i: nilai atribut
    - y_i: nilai numerik sebenarnya
  - *instance* uji x
- Algoritma:
  1. Hitung jarak $D(x, x_i)$ untuk semua x_i
  2. Pilih k tetangga terdekat dengan labelnya
  3. $\hat{y} = f(x) = \frac{1}{k} \sum_{j=1}^{k} y_{ij}$ (nilai rata-rata)

Regresi k-NN

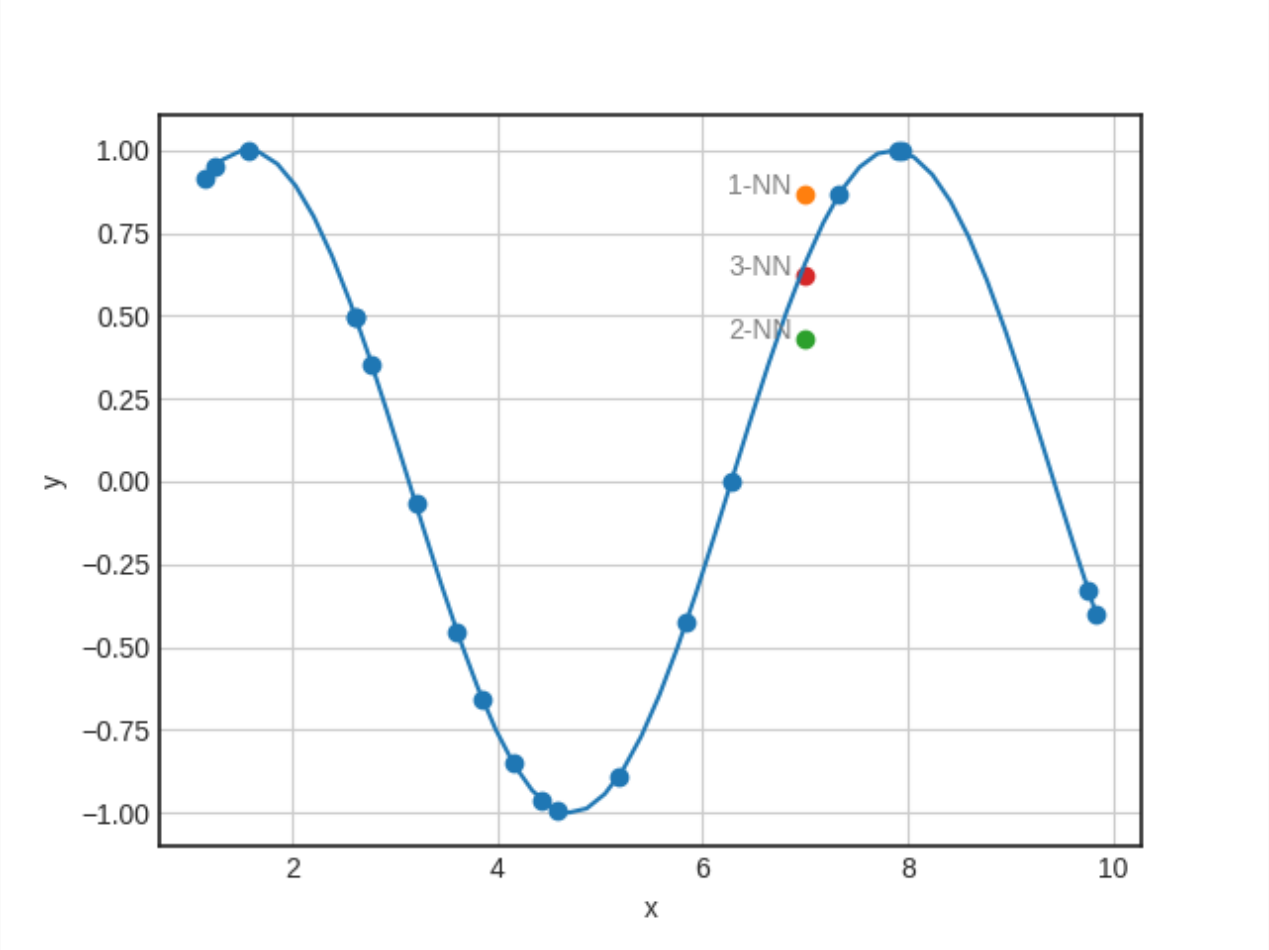

Figure 5: Interpolasi dengan $\{1,2,3\}$-NN

Regresi k-NN

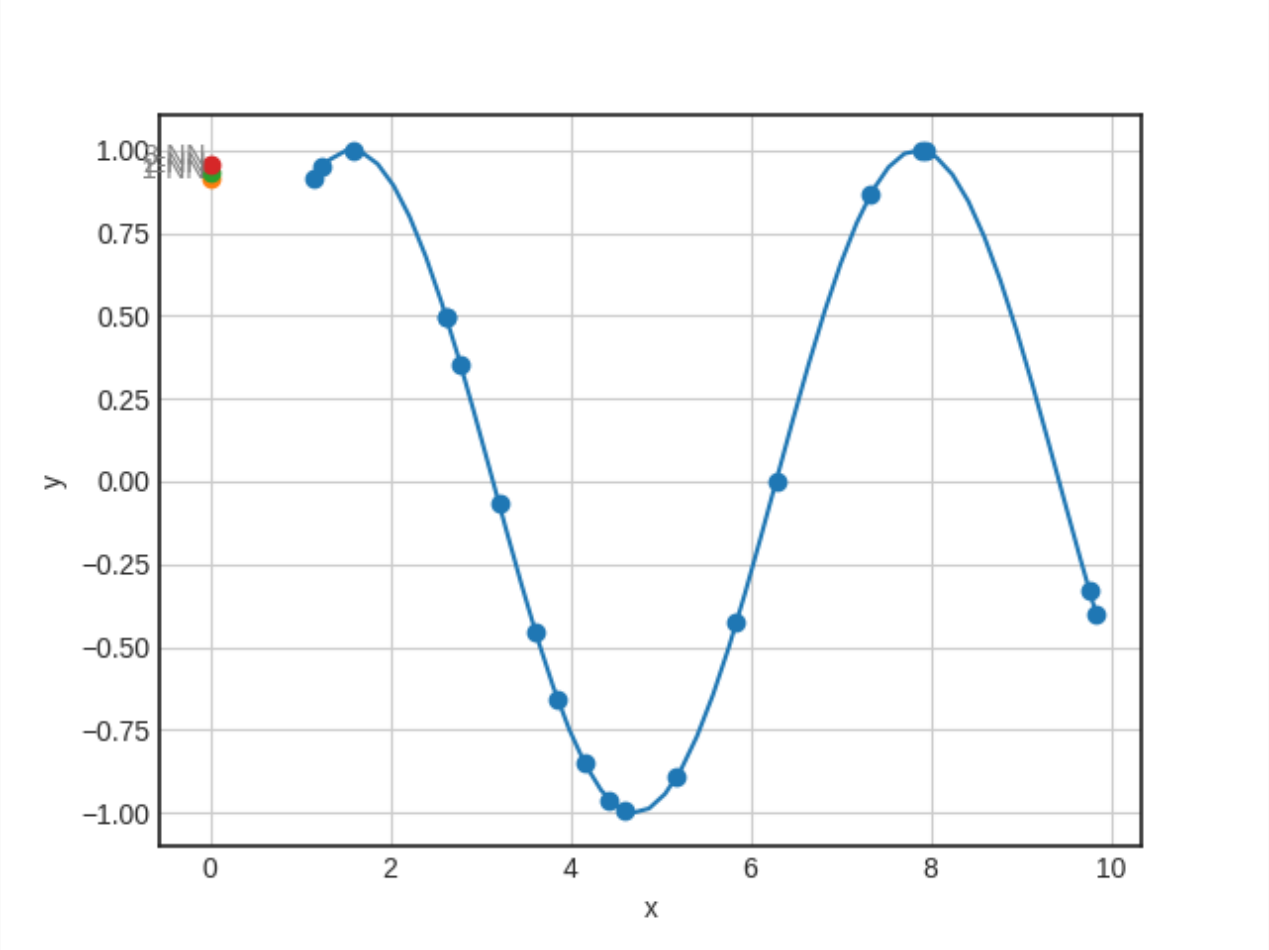

Figure 6: Ekstrapolasi dengan {1,2,3}-NN

Tuning

Bagaimana cara memilih nilai k?

Memilih Nilai k

- Nilai yang besar $\rightarrow P(y)$ atau $\bar{y}$
- Nilai yang kecil $\rightarrow$ terlalu variatif, batas keputusan yang tidak stabil

Memilih Nilai k

- Nilai yang besar $\rightarrow P(y)$ atau $\bar{y}$
- Nilai yang kecil $\rightarrow$ terlalu variatif, batas keputusan yang tidak stabil
- **Solusi:** Gunakan data validasi!

Batas Keputusan

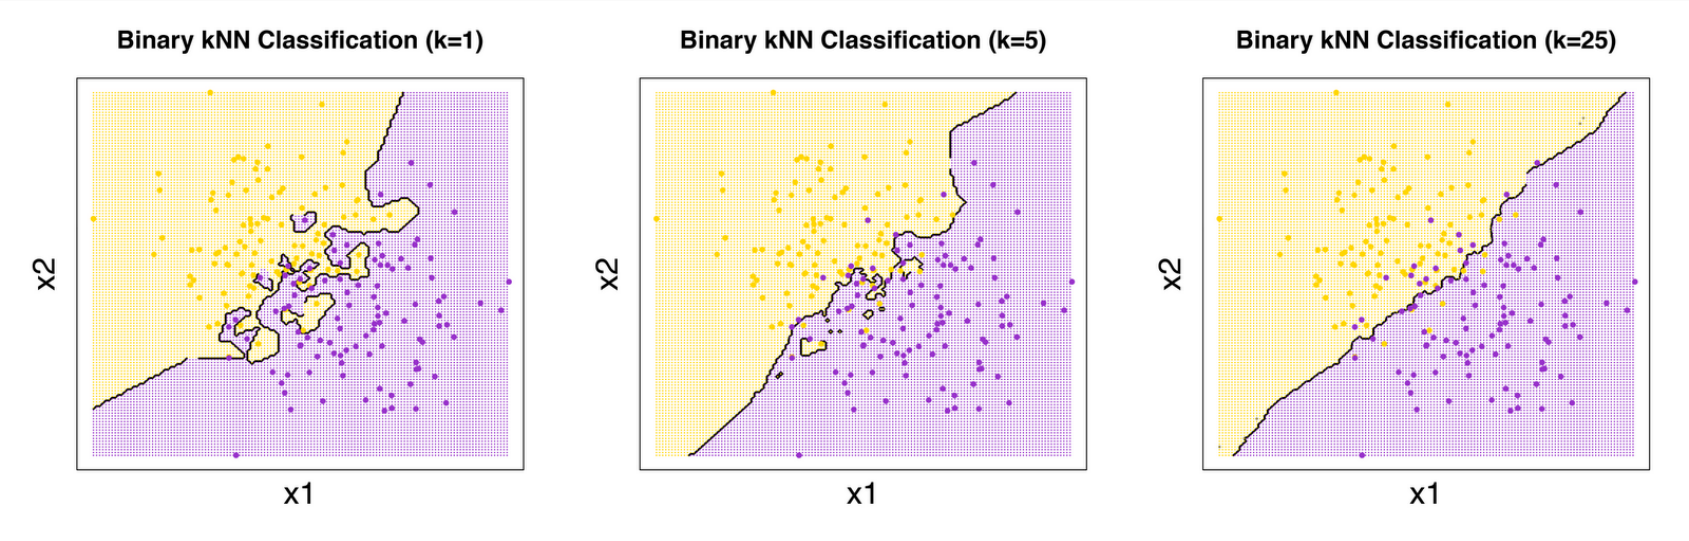

Figure 7: Pengaruh nilai k pada batas keputusan [DeWilde, 2012]

Isu

- Hasil seri:
  1. Gunakan jumlah k ganjil
  2. Acak, lemparan koin
  3. *Prior probability*
  4. 1-NN
- *Missing values:* harus diganti (*impute*)
- Rentan terhadap perbedaan rentang variabel

Perbedaan Rentang

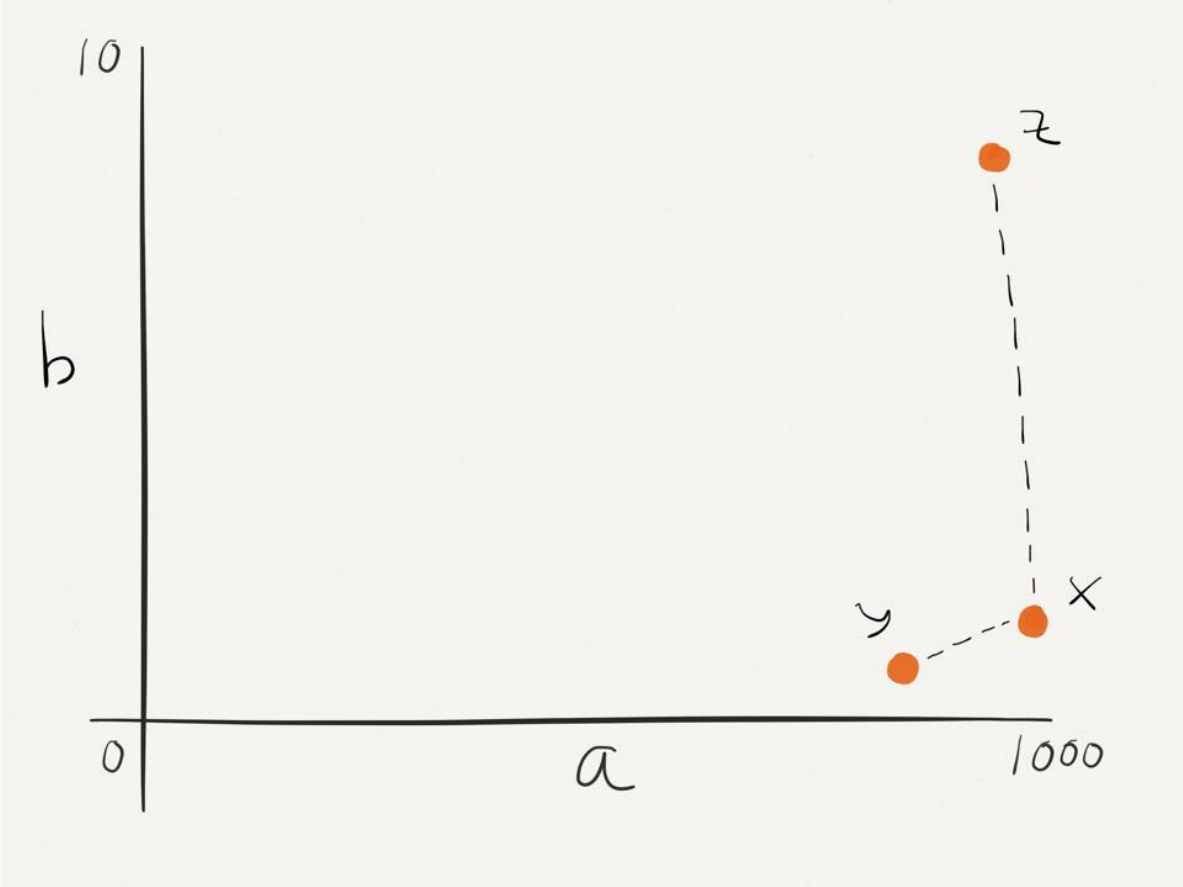

Figure 8: Perbedaan rentang variabel bisa mengacaukan klasifikasi k-NN [Wibisono, 2015]

Pros & Cons

- Pros:
  - Tidak ada asumsi terhadap data, non-parametrik
  - *Asymptotically correct*
- Cons:
  - Harus mengganti nilai yang hilang
  - Sensitif terhadap kelas pencilan (data latih yang salah dilabeli)
  - Sensitif terhadap atribut yang irelevan
  - **Mahal secara komputasi** $O(nd)$

Ikhtisar

- k-Nearest Neighbours merupakan algoritma yang dapat dipakai untuk klasifikasi dan regresi
- Nilai k dalam algoritma k-NN perlu divalidasi
- k-NN bersifat non-parametrik

Pertemuan berikutnya

- Unsupervised learning
- k-Means clustering

Referensi

- Burton DeWilde (26 Oktober 2012)
  Classification of Hand-written Digits (3)
  http://bdewilde.github.io/blog/blogger/2012/10/26/classification-of-hand-written-digits-3/
- Okiriza Wibisono (16 September 2015)
  kNN: Perhitungan Jarak, serta Batasan dan Keunggulan
  https://tentangdata.wordpress.com/2015/09/16/knn-perhitungan-jarak-serta-keunggulan-dan-batasan/

Terima kasih